

MÓDULO 2 · PYTHON PARA ANÁLISIS DE DATOS — CLASE 6

Manipulación de datos

Series y DataFrames con Pandas

Bootcamp de Ciencia de Datos · 2 horas · Uso de Series y DataFrames para almacenar y consultar datos

BIENVENIDA

El mapa del bootcamp: 6 módulos, 32 clases

MÓDULO 1**Fundamentos y Mentalidad de Datos**

Completado

MÓDULO 2**Python para Análisis de Datos**

Estamos aquí

MÓDULO 3**Visualización y Business Intelligence**

Gráficas, EDA, Power BI

MÓDULO 4**Extracción de Datos**

Bases de datos, SQL, APIs

MÓDULO 5**Machine Learning Básico y Aplicado**

Clasificación, regresión, clustering

MÓDULO 6**Proyecto Final y Cierre**

Deep Learning, NLP, tu proyecto

32 CLASES**Tu recorrido completo**

Mayo a septiembre, 2 clases por semana

CÓMO TRABAJAMOS

Teoría + práctica en cada módulo · talleres integradores · proyecto final

Hoy tus datos dejan de ser listas sueltas: se convierten en tablas que puedes consultar, filtrar y resumir en segundos.

POR QUÉ HOY IMPORTA

De listas y diccionarios a tablas de miles de filas

Pandas para tus datos

La librería pilar para trabajar con tablas

- Hasta ahora guardabas datos en listas y diccionarios, y los recorrías con ciclos.
- Los datos reales llegan como tablas: archivos CSV o Excel con miles de filas.
- Pandas los carga, los consulta y los resume sin ciclos, gracias a la vectorización.
- Es la herramienta que vas a usar en casi todo lo que sigue en el bootcamp.

¿Por qué justo ahora?



Ya sabes escribir lógica

Variables, estructuras, ciclos y funciones. Ahora los aplicas sobre datos reales, en formato de tabla.



Reemplaza trabajo manual

Lo que haces en Excel con filtros y tablas dinámicas queda escrito una vez y se repite en segundos.



Es la base de lo que sigue

Limpieza, visualización y Machine Learning parten de un DataFrame.

Hoy cargas una tabla real y la consultas con código.

CLASE 6

Lo que vamos a lograr hoy



01

Cargar y explorar una tabla

Leer un CSV con `read_csv` y revisarlo con `head`, `tail`, `info` y `describe`.



02

Preguntarle a los datos

Seleccionar columnas y filtrar filas con máscaras booleanas, usando `&` y `|`.



03

Transformar y resumir

Crear columnas vectorizadas, agrupar con `groupby` y exportar el resultado.

Al final de la clase: un análisis completo de ventas de videojuegos, de la carga a la exportación.

MÓDULO 2 · PANDAS

Entonces, ¿qué es Pandas?

La librería pilar de Python para manipular y analizar datos tabulares: tablas como las de Excel, con miles de filas y varias columnas.



Series

Una columna de datos: unidimensional.



DataFrame

Una tabla completa, formada por varias Series.



Vectorización

Operaciones sobre columnas completas, sin ciclos for ni while.



Archivos

Lee y guarda CSV y Excel con una sola línea de código.

Chequeo rápido: ¿qué ventaja tiene sumar dos columnas con `df['a'] + df['b']` frente a recorrerlas con un ciclo?

MÓDULO 2 · PANDAS

Explorar, filtrar y resumir



Explorar

Conocer la tabla.

- `head()` y `tail()`: primeras y últimas filas
- `info()`: tipos de dato y nulos
- `describe()`: estadísticas rápidas

Diagnóstico inicial



Filtrar

Quedarte con lo que importa.

- Una condición crea una máscara
- `&` significa Y, `|` significa O
- Cada condición entre paréntesis

`df[condicion]`



Resumir

Responder por categorías.

- `groupby()` agrupa por una columna
- Se aplica una suma o un promedio
- Devuelve un resultado por grupo

Dividir, aplicar, combinar

La pregunta que guía todo: ¿qué quieres saber de los datos, y qué parte de la tabla responde eso?

MÓDULO 2 · PANDAS

El ciclo de trabajo con un DataFrame

1. Cargar: convierte un archivo CSV o Excel en una tabla.

`read_csv()`

2. Explorar: revisa filas, tipos de dato, nulos y estadísticas.

`info()`

3. Filtrar: te quedas solo con las filas que cumplen una condición.

`df[mascara]`

4. Resumir: agrupas por una columna y calculas una suma o un promedio.

`groupby()`


5. Exportar: guardas el resultado en un archivo para compartirlo.

`to_csv()`

Estos cinco pasos se repiten en cualquier análisis, sin importar el tamaño de los datos.

MÓDULO 2 · PANDAS

Un análisis de ventas, paso a paso



La idea clave: ningún paso usa un ciclo for: Pandas aplica cada operación a columnas y grupos completos. Eso es la vectorización.

MÓDULO 2 · PANDAS

Entonces, ¿qué es una máscara booleana?



Una columna de True y False

Al comparar una columna con un valor, Pandas devuelve True o False por cada fila. Esa serie es la máscara: al pasarla entre corchetes, el DataFrame conserva solo las filas donde vale True.

Primero creas la condición, luego la aplicas.

Un ejemplo aplicado

```
condicion = df_ventas['Unidades_Vendidas'] > 20 genera True o False por fila. df_ventas[condicion] muestra solo las 8 ventas de más de 20 unidades.
```

Dato: para combinar condiciones usa & (Y) y | (O), con cada condición entre paréntesis. Las palabras and y or no funcionan con columnas.

MANOS A LA OBRA · 25 MIN

Actividad: ¿qué se vende más?

1

Carga `ventas_videojuegos.csv` en `df_ventas`. Muestra las primeras filas y revisa `info()`: ¿cuántas filas y columnas hay?

5 min

2

Crea la columna `Ingreso_Estimado` multiplicando `Precio_Unitario` por `Unidades_Vendidas`.

5 min

3

Filtra las ventas de la región `Latinoamerica` con más de 20 unidades, combinando las dos condiciones con `&`.

7 min

4

Agrupar por `Plataforma`, suma `Unidades_Vendidas` y ordénalas de mayor a menor. ¿Cuál lidera?

8 min



Entregable

Una captura de pantalla con:

- El resultado de `info()` con filas y columnas
- El filtro de `Latinoamérica` con más de 20 unidades
- El resumen por plataforma, ordenado

Esta secuencia (cargar, filtrar, calcular y agrupar) es la base de cualquier análisis de ventas.

Si el filtro da error, revisa que cada condición vaya entre paréntesis y que uses `&` en lugar de `and`.

CIERRE DE ACTIVIDAD · 10 MIN

Puesta en común: ¿qué plataforma lidera?



Algunos voluntarios comparten

Cada quien muestra su código y el resumen por plataforma.



Los demás retan

¿El filtro devuelve las filas esperadas?
¿Cada condición estaba entre paréntesis?



Buscamos patrones

¿La plataforma que más unidades vende es también la que más ingresos genera?

Pregunta de cierre: si quisieras saber qué videojuego vende más, ¿por qué columna agruparías?

RECAPITULEMOS

Las 4 ideas que se llevan hoy

01**Series y DataFrames son la base**

Una Series es una columna; un DataFrame es una tabla de varias Series.

02**Una máscara booleana filtra filas**

Una condición da True o False por fila, y `df[condicion]` conserva los True.

03**Pandas opera sin ciclos**

Las operaciones vectorizadas trabajan sobre columnas completas a la vez.

04**groupby responde por categorías**

Divide la tabla en grupos, aplica una suma o promedio y combina el resultado.

Mini-reto de salida (1 frase): explícale a alguien qué hace una máscara booleana, con un ejemplo de ventas.