BIT BUILD INNOVATE TRANSFORM

BIT BUILD INNOVATE TRANSFORM

MÓDULO 3 · VISUALIZACIÓN Y BUSINESS INTELLIGENCE · CLASE 12

Análisis exploratorio de datos

Conocer los datos primero

Bootcamp de Ciencia de Datos · 2 horas · Inspección inicial, calidad de los datos, análisis univariado y multivariado

BIT BUILD INNOVATE TRANSFORM

BIENVENIDA

El mapa del bootcamp: 6 módulos, 33 clases

MÓDULO 1

Fundamentos y Mentalidad de Datos

Completado

MÓDULO 2

Python para Análisis de Datos

Completado

MÓDULO 3

Visualización y Business Intelligence

Estamos aquí

MÓDULO 4

Extracción de Datos

Bases de datos, SQL, APIs

MÓDULO 5

Machine Learning Básico y Aplicado

Clasificación, regresión, clustering

MÓDULO 6

Proyecto Final y Cierre

Deep Learning, NLP, tu proyecto

33 CLASES

Tu recorrido completo

Mayo a septiembre, 2 clases por semana

CÓMO TRABAJAMOS

Teoría + práctica en cada módulo · talleres integradores · proyecto final

Hoy aprendemos a revisar un conjunto de datos con un orden, antes de sacar cualquier conclusión.

POR QUÉ HOY IMPORTA

Un análisis vale lo que valen sus datos

Del archivo al hallazgo

Lo que vamos a descubrir hoy

- Una tienda nos entrega 155 transacciones de clientes y quiere conocerlos.
- El archivo trae edades de 999 años, fechas en varios formatos y tres ciudades escritas de diez formas.
- Sin revisarlo, la mediana de la edad sale 66 años; bien revisado, 45,5.
- Al final sabremos qué se puede concluir con estos datos y qué no.

¿Por qué justo ahora?



Ya sabes limpiar y graficar

Duplicados, texto, tipos y vacíos, más los gráficos de las clases 10 y 11.



Ahora, un método

Un orden para revisar cualquier archivo nuevo, de la inspección a los hallazgos.



Decidir con criterio

Saber cuándo una variable no es confiable y qué reportar.

Explorar primero, concluir después.

CLASE 12

Lo que vamos a lograr hoy

01

Inspeccionar un archivo nuevo

Revisar tamaño, tipos, vacíos, duplicados y categorías siempre en el mismo orden.

02

Analizar variables y relaciones

Elegir el resumen y el gráfico según el tipo de variable: una sola, dos o varias.

03

Distinguir errores de patrones

Decidir qué es un error, qué es un atípico real y qué es un hallazgo, y anotar cada decisión.

Al final de la clase: el archivo de clientes explorado y una lista de hallazgos y problemas abiertos.

MÓDULO 3 · ANÁLISIS EXPLORATORIO

Entonces, ¿qué es el EDA?

Es examinar, resumir y visualizar un conjunto de datos para entender su estructura, su calidad y sus patrones antes de hacer modelos o sacar conclusiones.



Detectar errores

Imposibles, vacíos, duplicados y texto inconsistente.



Entender variables

Valores típicos, dispersión y forma.



Encontrar relaciones

Qué cambia junto y qué grupos difieren.



Generar hipótesis

Explicaciones posibles que luego se comprueban.

Chequeo rápido: ¿el EDA demuestra que una variable causa otra?

MÓDULO 3 · ANÁLISIS EXPLORATORIO

Un EDA paso a paso

Inspección

shape, info, head y describe

primer vistazo

→

Calidad

Vacíos, duplicados, imposibles y categorías

qué está mal

→

Univariado

Cada variable sola: histograma, cajas, barras

una variable

→

Multivariado

Dispersión, grupos, línea y mapa de calor

dos o más

→

Hallazgos

Pocos, claros y con su evidencia

qué concluir

El EDA es un ciclo: cada respuesta abre una pregunta nueva, y después de limpiar se vuelve a explorar.

MÓDULO 3 · ANÁLISIS EXPLORATORIO

Qué usar según el tipo de variable



Una variable

describe() y value_counts()

- Numérica: histograma y cajas
- Categórica: barras
- Busca imposibles y variantes

Edad: 83 imposibles



Dos variables

corr(), groupby(), crosstab()

- Numérica y numérica: dispersión
- Categórica y numérica: cajas
- Fecha y numérica: línea por mes

Mira más allá del promedio



Varias variables

sns.heatmap(df.corr())

- hue separa por color
- Subgráficos por grupo
- Revisa por subgrupos

Un patrón no es una causa

El tipo de variable decide la herramienta: un identificador es un número, pero no tiene sentido promediarlo.

TALLER GUIADO · DURANTE LA CLASE

El recorrido del cuaderno

1	Inspección y tipos: Transaction_ID, ingreso con caracteres extraños y fechas en varios formatos.	25 min
2	Calidad: valores imposibles, vacíos, duplicados y llaves repetidas.	25 min
3	Univariado: edad, género, ciudad y suscripción, antes y después de normalizar.	20 min
4	Multivariado: dispersión, mapa de calor y compras por mes.	20 min

Entregable

Tu cuaderno con:

- El archivo limpio paso a paso
- Los gráficos de cada variable
- Una lista de hallazgos

Pregunta siempre: ¿este valor es posible?

EDA resume la teoría; la práctica se hace en EDA - Practica junto con el docente.

RECAPITULEMOS

Las 4 ideas que se llevan hoy

01 **El EDA va antes de concluir**

Examinar, resumir y visualizar para entender estructura, calidad y patrones.

02 **El tipo de variable decide la herramienta**

Una, dos o varias variables: cada combinación tiene su resumen y su gráfico.

03 **No todo lo raro es un error**

Error, atípico real y patrón se tratan distinto; el contexto decide.

04 **Las decisiones cambian los datos**

El orden de la limpieza y la imputación pueden fabricar o borrar patrones.

Mini-reto de salida (1 frase): ¿usarías la columna de edad para una campaña? ¿Por qué?